UC2 · ANALISTA DE DADOS

AULA

01

VEnv, Jupyter Notebook e Introdução ao DataFrame

Prof. Cassio Ribeiro · SENAC RJ · 2025

OBJETIVOS DA AULA

- Identificar variáveis qualitativas e quantitativas
- Criar e ativar um Ambiente Virtual (VEnv) via CMD
- Configurar o Jupyter Notebook no VS Code (.ipynb)
- Conhecer a biblioteca Pandas e o openpyxl
- Criar DataFrames manualmente e a partir de arquivos .xlsx
- Realizar operações básicas: sum(), mean(), max(), min()

VARIÁVEIS: QUALITATIVA E QUANTITATIVA

QUALITATIVA

Descreve uma característica
ou categoria – .

- Nome do vendedor
- Produto
- Categoria
- Região

QUANTITATIVA

Expressa um valor numérico
mensuráve — é um número.

- Quantidade vendida
- Valor unitário
- Total da venda
- Número de clientes

✏ EXERCÍCIO RÁPIDO — Classifique: Cidade do cliente | Preço do produto | Nome do vendedor | Lucro | Tipo de pagamento

Por que dicionários?

- Listas armazenam valores sem rótulos — difícil saber o que cada posição significa.
- Dicionários usam chave → valor, tornando os dados legíveis e organizados.
- Chaves = nomes das colunas.
- Valores = listas com os dados de cada coluna.
- É a estrutura ideal para criar um DataFrame manualmente.

```python
# Estrutura de um dicionário
dados = {
    "vendedor": ["Ana", "Carlos", "Beatriz"],
    "produto":  ["Notebook", "Mouse", "Cadeira"],
    "total":    [3200, 269.70, 1500.00]}


# Acessando um valor
print(dados["vendedor"])
# ['Ana', 'Carlos', 'Beatriz']

# Isso é exatamente como o Pandas
# recebe dados para criar um DataFrame
```

📦 **Biblioteca = uma caixa de ferramentas pronta.**

Em vez de escrever tudo do zero, importamos funções já criadas e testadas por especialistas.

O que é o Pandas?

Biblioteca Python para manipulação e análise de dados tabulares. Trabalha com linhas, colunas e tabelas — como uma planilha, mas muito mais poderosa.

O que é um dataset?

Um conjunto de dados estruturado — geralmente uma tabela com linhas (registros) e colunas (variáveis). Pode vir de um arquivo, banco de dados ou API.

Instalação e importação

```
pip install pandas

import pandas as pd

# 'pd' é o apelido padrão da comunidade
```

AMBIENTE VIRTUAL — VEnv

❌ Sem VEnv

Bibliotecas instaladas globalmente geram conflitos entre versões de projetos diferentes.

✅ Com VEnv

Cada projeto tem seu próprio ambiente isolado, com as versões exatas que ele precisa.

CMD — Passo a passo

```
python -m venv meu_env                    # cria o ambiente virtual na pasta atual
meu_env\Scripts\activate                  # ativa o ambiente  (Windows)
pip install pandas openpyxl               # instala as bibliotecas necessárias
pip freeze                                # lista todas as bibliotecas instaladas
pip freeze > requirements.txt             # salva as dependências em arquivo
pip install -r requirements.txt           # recria o ambiente em outra máquina
deactivate                                # desativa o ambiente
```

Por que usar o Jupyter Notebook?

- Execução célula a célula — ideal para explorar dados aos poucos.
- Resultados aparecem inline, logo abaixo do código.
- DataFrames são exibidos como tabelas formatadas.
- Células Markdown permitem documentar a análise.
- Arquivo gerado com extensão .ipynb

⚙ Configuração no VS Code

1. Instalar extensão **Python**
2. Instalar extensão **Jupyter**
3. Na primeira execução: selecionar o **kernel** apontando para o VEnv criado

print() vs display()

```
import pandas as pd

dados = {
  "vendedor": ["Ana","Carlos"],
  "total":    [3200, 270]}

df = pd.DataFrame(dados)

print(df)      # texto simples
display(df)    # tabela visual ✓
```

💡 No Jupyter, prefira sempre display() para ver DataFrames.

CÉLULAS NO JUPYTER

CÉLULA DE CÓDIGO

Onde escrevemos e executamos Python.
O resultado aparece logo abaixo.

```
import pandas as pd


df = pd.DataFrame({'x': [1,2,3]})

display(df)
```

CÉLULA DE MARKDOWN

Para documentar, explicar e organizar
o notebook com texto formatado.

```
# Análise de Vendas NaraStore

## 1. Carregamento dos dados

Nesta etapa carregamos o arquivo

vendas.xlsx e verificamos o total.
```

ATALHOS:

Shift + Enter executa e avança para a próxima célula

Ctrl + Enter executa e permanece na célula atual

CRIANDO UM DATAFRAME

DataFrame = uma tabela de dados com linhas e colunas — pense numa planilha Excel, só que dentro do Python.

```
import pandas as pd

dados = {
  "vendedor": ["Ana","Carlos","Beatriz"],
  "produto":  ["Notebook","Mouse","Cadeira"],
  "total":    [3200, 269.70, 1500.00]}

df = pd.DataFrame(dados)
display(df)
```

Resultado:

	vendedor	produto	total
0	Ana	Notebook	3200.00
1	Carlos	Mouse	269.70
2	Beatriz	Cadeira	1500.00

💡 O índice (0, 1, 2...) é criado automaticamente pelo Pandas. Cada coluna do dicionário vira uma coluna do DataFrame.

LENDO UM ARQUIVO .xlsx COM PANDAS

⚠ O Pandas não lê .xlsx por padrão — ele precisa do openpyxl como motor de leitura. → pip install openpyxl

```
# Leitura simples
df = pd.read_excel("vendas_narastore.xlsx")
display(df)

# Por intervalo de colunas
df = pd.read_excel(
    "vendas_narastore.xlsx",
    usecols="A:G")

# Por nome das colunas
df = pd.read_excel(
    "vendas_narastore.xlsx",
    usecols=["Vendedor","Total (R$)"])
```

Por que usar usecols?

- Planilhas reais frequentemente têm mais de uma tabela na mesma aba.
- Sem usecols, o Pandas lê tudo — inclusive colunas que não pertencem à sua tabela.
- Com usecols você define exatamente quais colunas importar, evitando dados incorretos.
- Também melhora o desempenho em arquivos grandes.

OPERAÇÕES BÁSICAS COM DATAFRAME

.sum()

Soma todos os valores da coluna

.mean()

Calcula a média aritmética

.max()

Retorna o maior valor da coluna

.min()

Retorna o menor valor da coluna

```
df = pd.read_excel("vendas_narastore.xlsx",
                   usecols="A:G")


total  = df["Total (R$)"].sum()
media  = df["Total (R$)"].mean()
maximo = df["Total (R$)"].max()
minimo = df["Total (R$)"].min()
```

Resultado:

Total vendido	**R$ 27.869,80**
Média por venda	**R$ 1.393,49**
Maior venda	**R$ 3.200,00**
Menor venda	**R$ 269,70**

NaraStore

Você foi contratado como estagiário de dados na NaraStore. O analista sênior enviou o arquivo vendas_narastore.xlsx e pediu que você prepare o ambiente, carregue os dados e responda:

"Qual foi o total vendido? Qual a média por venda? Qual a maior e menor venda registrada?"

Roteiro:

1. Crie e ative um VEnv via CMD
2. Instale pandas e openpyxl no VEnv
3. Abra o VS Code, crie um arquivo .ipynb e selecione o kernel do VEnv
4. Leia o arquivo vendas_narastore.xlsx usando usecols (colunas A:G)
5. Calcule: soma, média, máximo e mínimo da coluna Total (R$)
6. Responda as perguntas do sênior usando display()
7. Documente cada etapa com células Markdown

RESUMO DA AULA

✓ **Variáveis qualitativas e quantitativas identificadas**

`Classificamos dados por natureza`

✓ **VEnv criado e ativado via CMD**

`python -m venv + activate`

✓ **Pandas e openpyxl instalados**

`pip install no ambiente isolado`

✓ **Jupyter Notebook configurado no VS Code**

`Extensões Python + Jupyter + kernel selecionado`

✓ **DataFrame criado manualmente com dicionário**

`pd.DataFrame(dados)`

✓ **Arquivo .xlsx lido com usecols**

`pd.read_excel() + usecols`

✓ **Operações básicas aplicadas**

`sum() mean() max() min()`